K-MEANS算法

- 聚类概念：
  - 无监督问题：我们手里没有标签了
  - 聚类：相似的东西分到一组
  - 难点：如何评估，如何调参

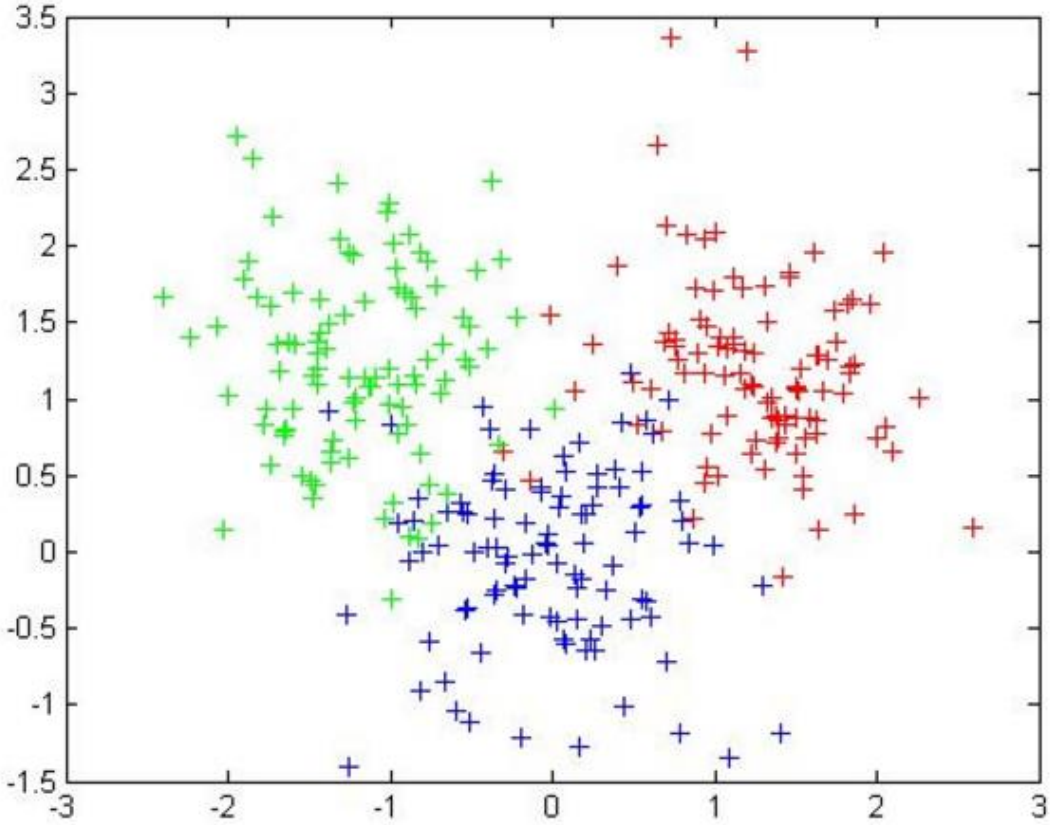

K-MEANS算法

- 基本概念：
  - 要得到簇的个数，需要指定K值
  - 质心：均值，即向量各维取平均即可
  - 距离的度量：常用欧几里得距离和余弦相似度（先标准化）
  - 优化目标：$\min \sum_{i=1}^{K} \sum_{x \in C_i} dist(c_i, x)^2$

K-MEANS算法

- 工作流程：

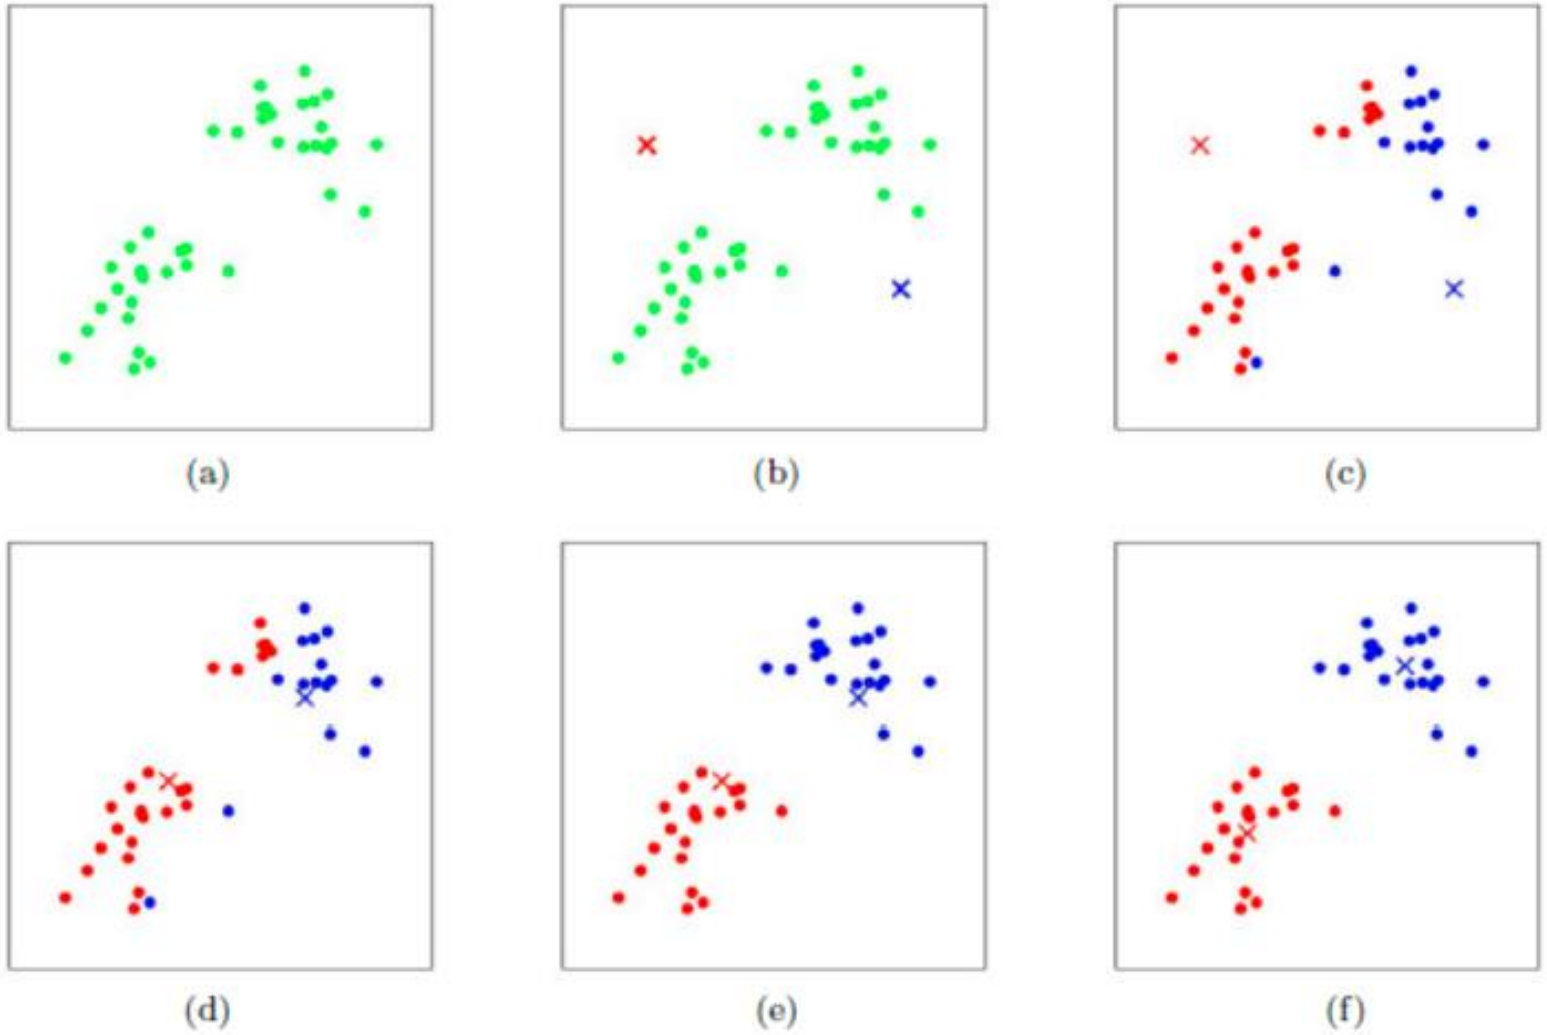

K-MEANS算法

- 优势：
  - 简单，快速，适合常规数据集
- 劣势：
  - K值难确定
  - 复杂度与样本呈线性关系
  - 很难发现任意形状的簇

受初始点影响大 !!!

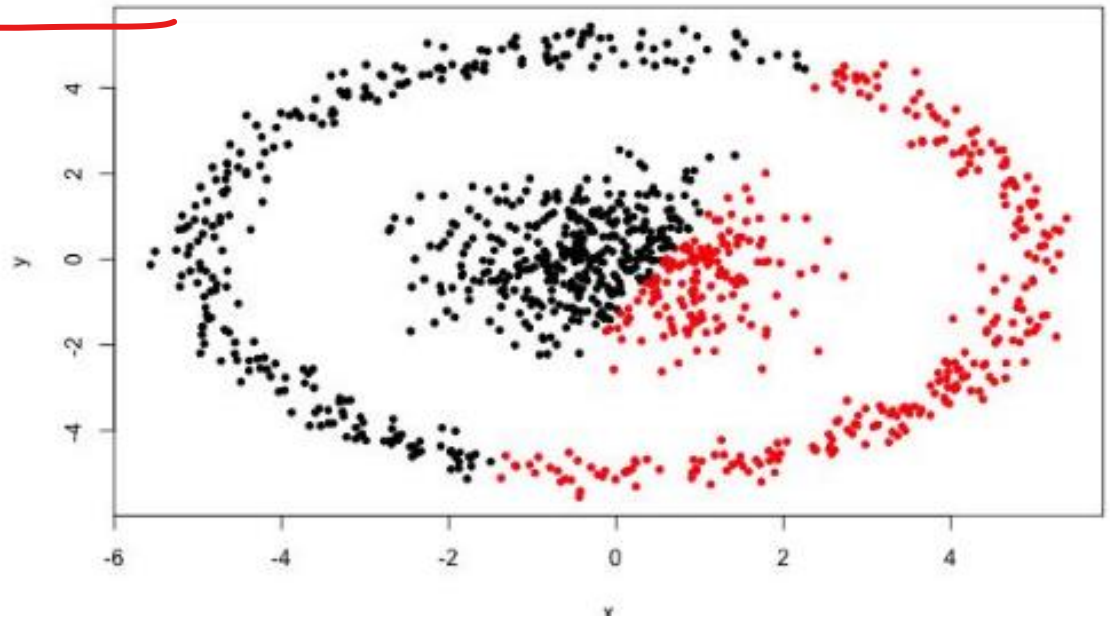

DBSCAN算法

基于 密度 空间 聚类

- 基本概念：（Density-Based Spatial Clustering of Applications with Noise）

  - 核心对象：若某个点的密度达到算法设定的阈值则其为核心点。（即 r 邻域内点的数量不小于minPts）
  - ϵ-邻域的距离阈值：设定的半径r

参数

epsilon ε 区域

miniPoints 在ε中至少应该出现的数据点个数

  - 直接密度可达：若某点p在点q的 r 邻域内，且q是核心点则p-q直接密度可达。
  - 密度可达：若有一个点的序列q0、q1、...qk，对任意qi-qi-1是直接密度可达的，则称从q0到qk密度可达，这实际上是直接密度可达的“传播”。

DBSCAN算法

- 基本概念：

  - 密度相连：若从某核心点p出发，点q和点k都是密度可达的,则称点q和点k是密度相连的。
  - 边界点:属于某一个类的非核心点,不能发展下线了
  - 直接密度可达：若某点p在点q的 r 邻域内，且q是核心点则p-q直接密度可达。
  - 噪声点：不属于任何一个类簇的点，从任何一个核心点出发都是密度不可达的

DBSCAN算法

- 基本概念：
  - A：核心对象
  - B,C：边界点
  - N：离群点

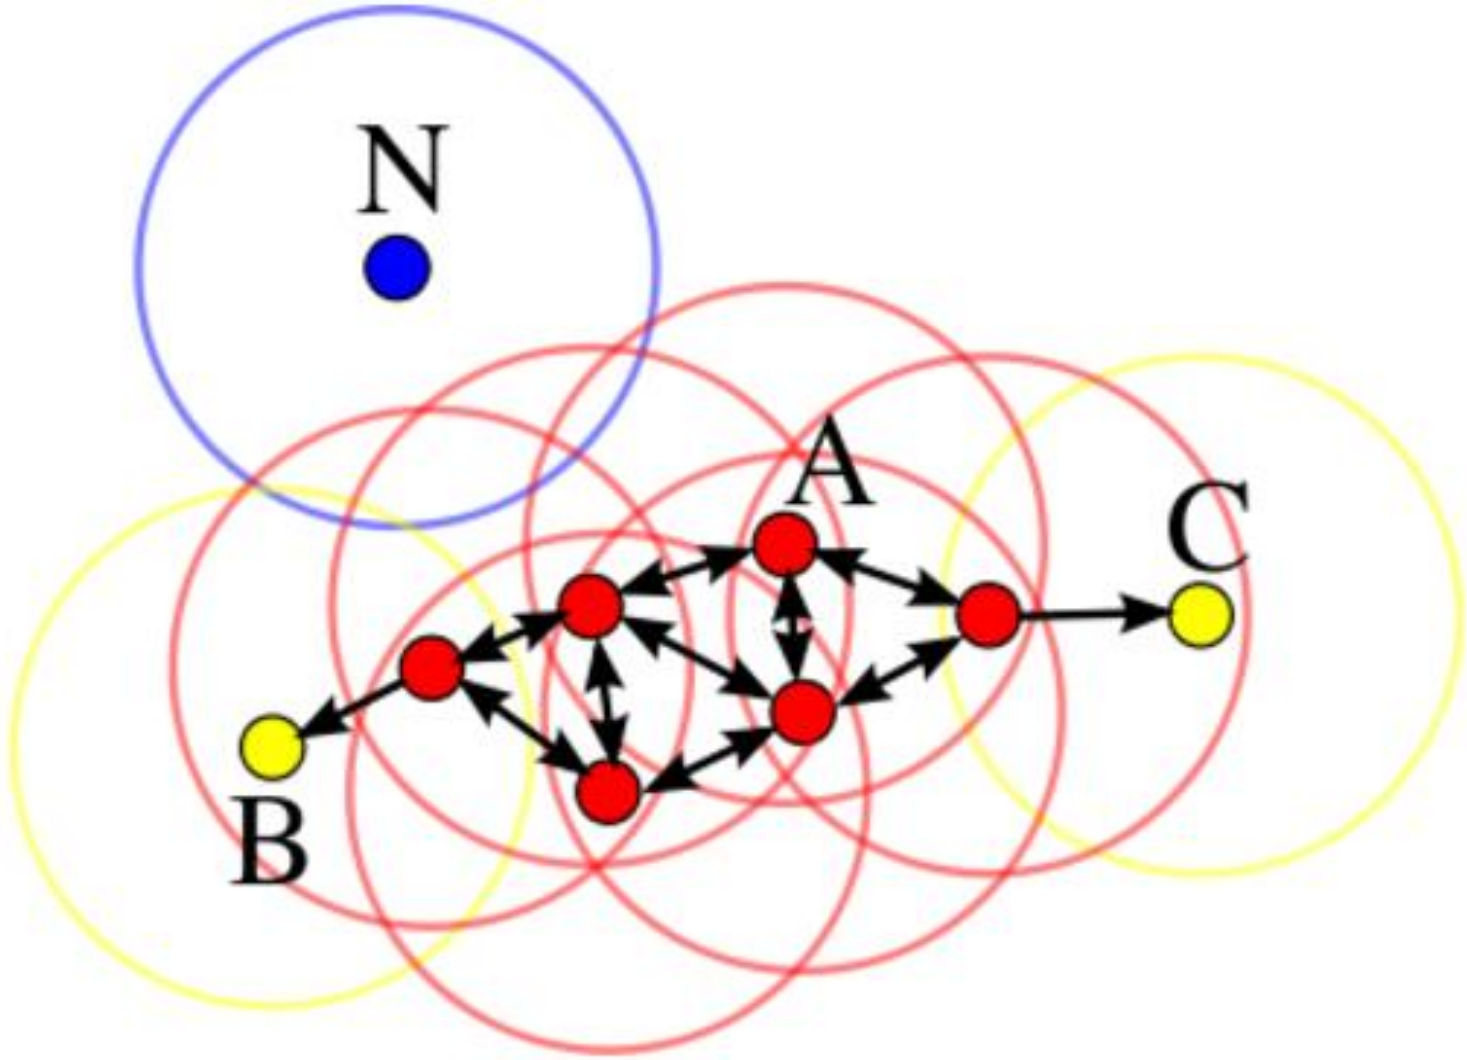

DBSCAN算法

- 工作流程：
  - 参数D：输入数据集
  - 参数ϵ：指定半径
  - MinPts：密度阈值

1. 标记所有对象为 unvisited;
2. Do
3. 随机选择一个 unvisited 对象 p;
4. 标记 p 为 visited;
5. If p 的 ε－领域至少有 MinPts 个对象
6. 创建一个新簇 C，并把 p 添加到 C;
7. 令 N 为 p 的 ε－领域中的对象集合
8. For N 中每个点 p'
9. If p' 是 unvisited;
10. 标记 p' 为 visited;
11. If p' 的 ε－领域至少有 MinPts 个对象，把这些对象添加到 N;
12. 如果 p' 还不是任何簇的成员，把 p' 添加到 C;
13. End for;
14. 输出 C;
15. Else 标记 p 为噪声;
16. Until 没有标记为 unvisited 的对象;

一个for处理一个类

DBSCAN算法

- 参数选择：

  - 半径ϵ，可以根据K距离来设定：找突变点
    K距离：给定数据集P={p(i); i=0,1,...n}，计算点P(i)到集合D的子集S中所有点之间的距离，距离按照从小到大的顺序排序，d(k)就被称为k-距离。

  - MinPts： k-距离中k的值，一般取的小一些，多次尝试

DBSCAN

K-means

可视化：https://www.naftaliharris.com/blog/visualizing-dbscan-clustering/
https://www.naftaliharris.com/blog/visualizing-k-means-clustering/

DBSCAN算法

- 优势：
  - 不需要指定簇个数
  - 可以发现任意形状的簇
  - 擅长找到离群点（检测任务）
  - 两个参数就够了

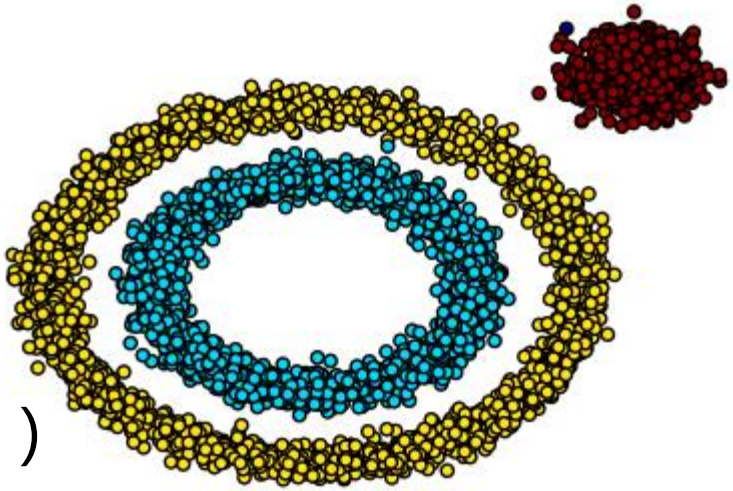

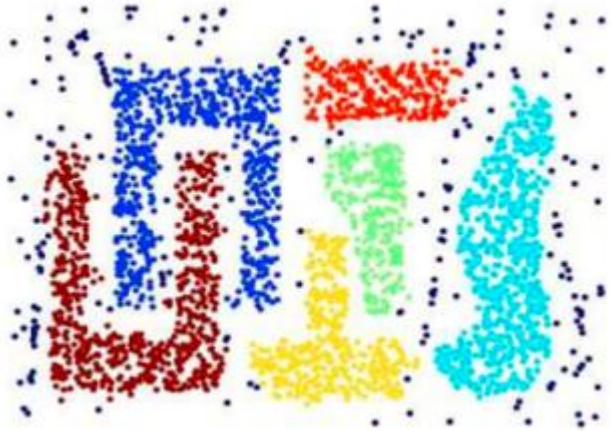

- 劣势：

https://www.naftaliharris.com/blog/visualizing-dbscan-clustering/

  - 高维数据有些困难（可以做降维）
  - 参数难以选择（参数对结果的影响非常大）
  - Sklearn中效率很慢（数据削减策略）